

Assistant GenAI pour l'exploitation de la documentation technique et de maintenance automobile

Entreprise Renault	Année 2025	Référence PFE-04
Domaine Generative AI - Recherche documentaire	Durée indicative 6 mois	Statut Sujet fictif - exercice RAG

Document créé uniquement pour un exercice pédagogique. Il ne correspond pas à une offre ou à un projet réel de l'entreprise citée.

Contexte

Les équipes techniques disposent d'un volume important de documentation : manuels de réparation, procédures de diagnostic, notes techniques, comptes rendus d'intervention et guides de maintenance. Ces informations sont réparties dans de nombreux documents, souvent longs, et leur consultation nécessite de connaître le bon document ainsi que le vocabulaire utilisé par les rédacteurs.

Renault souhaite expérimenter une interface conversationnelle permettant à un utilisateur de poser une question en langage naturel et d'obtenir une réponse fondée sur la documentation interne. Le système devra privilégier la traçabilité : une réponse ne devra pas seulement être fluide, elle devra permettre à l'utilisateur de retrouver les passages ayant servi à la générer.

Objectif du projet

Développer un prototype d'assistant documentaire basé sur une architecture Retrieval-Augmented Generation (RAG). Le prototype devra indexer un corpus de documents techniques, retrouver les passages pertinents pour une question, générer une réponse à partir de ces passages et afficher les sources associées.

Corpus documentaire

- manuels de maintenance au format PDF ;
- procédures de diagnostic et fiches de contrôle ;
- notes techniques portant sur plusieurs familles de composants ;
- documents de longueurs et de structures différentes, avec titres, tableaux et paragraphes techniques.

Travaux à réaliser

- extraire et nettoyer le texte des documents ;
- définir une stratégie de découpage des documents en segments ;
- générer des embeddings pour représenter les segments ;
- mettre en place un index vectoriel et une recherche par similarité ;
- construire le contexte envoyé au Large Language Model ;
- concevoir un prompt demandant au modèle de répondre uniquement à partir du contexte fourni ;
- afficher les documents ou passages utilisés comme sources ;
- constituer un jeu de questions et analyser séparément les erreurs de retrieval et les erreurs de génération.

Approche méthodologique

Indexation - Les documents seront découpés en chunks avant calcul des embeddings. Plusieurs tailles de chunks et niveaux de chevauchement pourront être comparés afin d'étudier leur effet sur la qualité du retrieval.

Retrieval - Pour chaque question, le système recherchera les segments les plus proches dans l'espace vectoriel. Le nombre de passages retournés (Top-K) devra être configurable pour permettre des expérimentations.

Génération et évaluation - Le LLM recevra uniquement la question et les passages récupérés. L'évaluation devra distinguer la pertinence des passages retrouvés de la fidélité de la réponse finale aux sources.

Résultats attendus

- un pipeline d'ingestion de documents ;
- un index vectoriel permettant la recherche sémantique ;
- une interface conversationnelle simple ;
- l'affichage des sources associées aux réponses ;
- un jeu de questions de test et une analyse des principales limites du prototype.

Mots-clés

Generative AI, LLM, RAG, embeddings, recherche sémantique, vector database, NLP, Python.